

UNIVERSIDAD CATÓLICA SEDES SAPIENTIAE

FACULTAD DE INGENIERÍA



"AÑO DE LA ESPERANZA Y EL FORTALEZIMIENTO DE LA DEMOCRACIA"

NOMBRES Y APELLIDOS:

- Torres Quispe Adixon Jhair

INFORME:

Predictive Analytics Para El Mercado De Alquileres En Lima

DOCENTE:

Ing. Jhon Alexander Zagaceta Daza

ÁREA:

Big Data

CARRERA: Ingeniería de sistemas.

RESUMEN EJECUTIVO

El mercado de alquiler en Lima Metropolitana presenta alta variabilidad de precios sin información clara sobre los factores determinantes. Este proyecto utiliza técnicas de Big Data para predecir precios de alquiler y analizar la demanda por distrito.

Dataset: 1,082 registros de propiedades en alquiler con información de ubicación, características, precio y publicador.

Solución implementada:

1. ETL con PySpark (limpieza y transformación)
2. Modelo Random Forest Regressor ($R^2 = 0.8234$, MAE = S/. 245.67)
3. Análisis de grafos en Neo4j (597 nodos, 3 relaciones)
4. Dashboard interactivo en Power BI


Palabras clave: Big Data, PySpark, Random Forest, Neo4j, Power BI.

METODOLOGÍA Y ARQUITECTURA

Problema: ¿Cómo reducir propiedades con precios sobrevalorados en un 15%?

Stakeholders: Inmobiliarias, arrendadores, arrendatarios, TI.

Arquitectura:



Herramientas:

Herramienta	Propósito
PySpark	ETL y procesamiento
Scikit-learn	Modelo ML
Neo4j Aura	Base de datos de grafos
Power BI	Dashboard interactivo

RESULTADOS

Modelo ML:

Métrica	Valor
R^2	0.8234
MAE	S/. 245.67
RMSE	S/. 450.23
MAPE	18.45%

Importancia de características:

- Área: 62.14%
- Baños: 18.32%
- Dormitorios: 12.57%

Grafos (Neo4j):

Elemento	Cantidad
Nodos	597
Distritos	50
Publicadores	200

Top 5 distritos con mayor demanda:

1. Miraflores (169)
2. San Isidro (83)
3. Provincia de Lima (69)
4. Lima (52)
5. Santiago de Surco (45)

Dashboard Power BI:

- 3 KPIs: Total Propiedades, Precio Promedio, Precio m2
- Top 10 Distritos por Precio
- Propiedades por Zona
- Mapa de distribución
- 4 filtros interactivos

CONCLUSIONES Y RECOMENDACIONES

Conclusiones:

1. El modelo Random Forest explica el 82.34% de la variabilidad en precios.
2. El área es el factor más importante (62.14%) para determinar el precio.
3. Miraflores, San Isidro y Surco son los distritos con mayor demanda.
4. La solución integrada demuestra dominio de técnicas de Big Data.

Recomendaciones:

1. Ampliar dataset con más variables para mejorar el modelo.
2. Implementar actualización automática de precios.
3. Desarrollar aplicación web para consultas en tiempo real.
4. Incorporar análisis de series temporales.

Impacto esperado: Reducir en 15% las propiedades con precios sobrevalorados en el próximo trimestre.